

コンピュータ アーキテクチャ I 第11回

塩谷 亮太 (shioya@ci.i.u-tokyo.ac.jp)

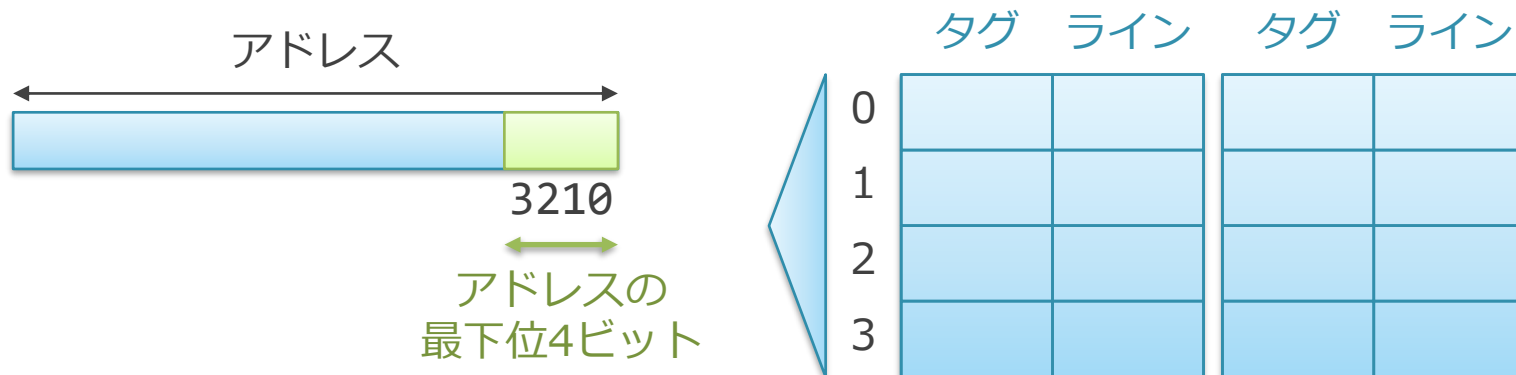
東京大学大学院情報理工学系研究科 創造情報学専攻

課題の解説

第10回課題


- すいません，おもってたよりムズいと言うか，手間がかかります
- 解説の準備が間に合いませんでした
 - お腹の調子が異常に悪く，検査と手術をしていました・・・
 - 後で解説の続きをアップロードして説明します

アドレスとラインの対応




- アドレスは1バイト単位でメモリの位置を表すものとする
- 最下位ビット 0 ～ 3 （計 4 ビット）
 - 最下位部分がライン内の位置に対応
 - 空間局所性を利用するために連続した 16 バイトが 1 ラインに
 - 4ビットなのは, ラインサイズが16バイトだから
 - $2^4 = 16$
 - (ラインサイズは必ず 2 の累乗になる)

アドレスとセットの対応



- ライン部分の上位にあるビット 4 ~ 5 （計2ビット）
 - この部分を使って、どのセットにアクセスするか決める
 - 2ビットなのは、セット数が4だから
 - $2^2 = 4$
 - セット数も必ず2の累乗になる
- アドレスのこの部分はなるべくばらけた方がよい
 - 同じセットにアクセスがいかず、競合がおきにくくなる

アドレスとタグの対応



	タグ	ライン	タグ	ライン
0				
1				
2				
3				

- 残りの上位のビットがタグとなる
- タグにはセット（赤）やライン（緑）の部分は入れないでよい
 - あるセットにアクセスするアドレスは、赤部分は常に一定だから
 - セット 1 にアクセスする場合、赤部分は絶対 01
 - 緑部分はラインの中の位置を表すので、関係ない

課題 10

- アドレスの幅が 16 bit, ラインサイズ8B, 4 エントリのキャッシュについて考える
- 連想度を以下の様に変えた場合に,
 - 1 (ダイレクトマップ)
 - 2
 - 4 (フルアソシアティブ)
- 以下のようなアドレスによる 1B のアクセスがあった場合を考える
 1. 0x8000, 0x8001, 0x8002, 0x8003, 0x8000, 0x8001, 0x8002, 0x8003
 2. 0x8000, 0x9000, 0xA000, 0xB000, 0x8000, 0x9000, 0xA000, 0xB000
 3. 0x8000, 0x9001, 0x8002, 0x9003, 0x9004, 0xA005, 0x9006, 0x8007

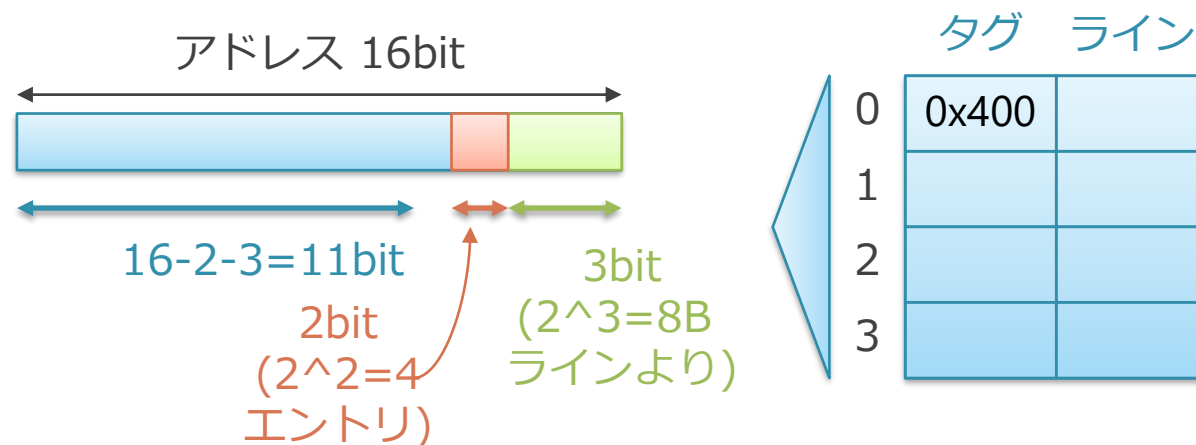
課題 10

- (1) 上記それぞれの場合で、アクセスが全て終わった後のキャッシュの状態（タグの中身）を示せ
 - 4 エントリのタグにそれぞれ何が残っているかを、
連想度3パターン×アクセス系列3パターン= 9 パターン分答える
- (2) 上記それぞれの場合のヒット率を計算せよ
- (3) 各アクセスにおけるヒット時に、それが空間的局所性と時間的局所性のいずれによるのかを分類して答えよ
- 多少多いかもですが、
 - 途中までしか出来なくても良いです
 - 試験までには1回解いておくの良いです
 - 実は (1) がちゃんとできれば (2) と (3) はおまけみたいなものです

課題 10

■ 考え方：

- アドレスの系列を全部2進数に直す
- 下の図の割り当てごとに分類する
 - 上から順に、タグ、インデックス、ラインの3つに分類される
 - インデックス部分からキャッシュのどこにアクセスされるかが決まる
 - ◇ テーブルの何行目のエントリに行くか
- タグを対応するエントリにテーブルに上書きしていく
- 対応するエントリに同じタグがある = hit, ない=miss
 - 全く同じアドレスにアクセスした事がある hit=時間局所性
 - 全く同じアドレスにはアクセスしていないが hit = 空間局所性



課題 10

1. 0x8000, 0x8001, 0x8002, 0x8003, 0x8000, 0x8001, 0x8002, 0x8003
インデックスとタグを決定するビットが全部同じ = 同じライン

1. 0x8000 = 0b1000 0000 0000 0000 miss
2. 0x8001 = 0b1000 0000 0000 0001 hit 空間的局所性
3. 0x8002 = 0b1000 0000 0000 0010 hit 空間的局所性
4. 0x8003 = 0b1000 0000 0000 0011 hit 空間的局所性
5. 0x8000 = 0b1000 0000 0000 0000 hit 時間的局所性 or 空間的局所性
6. 0x8001 = 0b1000 0000 0000 0001 hit 時間的局所性 or 空間的局所性
7. 0x8002 = 0b1000 0000 0000 0010 hit 時間的局所性 or 空間的局所性
8. 0x8003 = 0b1000 0000 0000 0011 hit 時間的局所性 or 空間的局所性
0b100 0000 0000=0x400

タグ

0	0x400
1	
2	
3	

課題 10

1. 0x8000, 0x9000, 0xA000, 0xB000, 0x8000, 0x9000, 0xA000, 0xB000
インデックスを決定するビットが全部同じ = 同じエントリに入る
最後にアクセスされた 0xb000 の分が残る

1. 0x8000 = 0b1000 0000 0000 0000 miss
2. 0x9000 = 0b1001 0000 0000 0000 miss
3. 0xA000 = 0b1010 0000 0000 0000 miss
4. 0xB000 = 0b1011 0000 0000 0000 miss
5. 0x8000 = 0b1000 0000 0000 0000 miss
6. 0x9000 = 0b1001 0000 0000 0000 miss
7. 0xA000 = 0b1010 0000 0000 0000 miss
8. 0xB000 = 0b1011 0000 0000 0000 miss 0b101 1000 0000=0x580

タグ

0	0x580
1	
2	
3	

課題 10

1. 0x8000, 0x9001, 0x8002, 0x9003, 0x9004, 0xA005, 0x9006, 0x8007

1. 0x8000 = 0b1000 0000 0000 0000 miss

2. 0x9001 = 0b1001 0000 0000 0001 miss

3. 0x8002 = 0b1000 0000 0000 0010 miss

4. 0x9003 = 0b1001 0000 0000 0011 miss

5. 0x9004 = 0b1001 0000 0000 0100 hit 空間局所性

6. 0xA005 = 0b1010 0000 0000 0101 miss

7. 0x9006 = 0b1001 0000 0000 0110 miss

8. 0x8007 = 0b1000 0000 0000 0111 miss

0b100 0000 0000=0x400

タグ

0	0x400
1	
2	
3	

仮想メモリと特権モード

今日の内容

1. 仮想メモリ

1. モチベーションと基本
2. 詳細

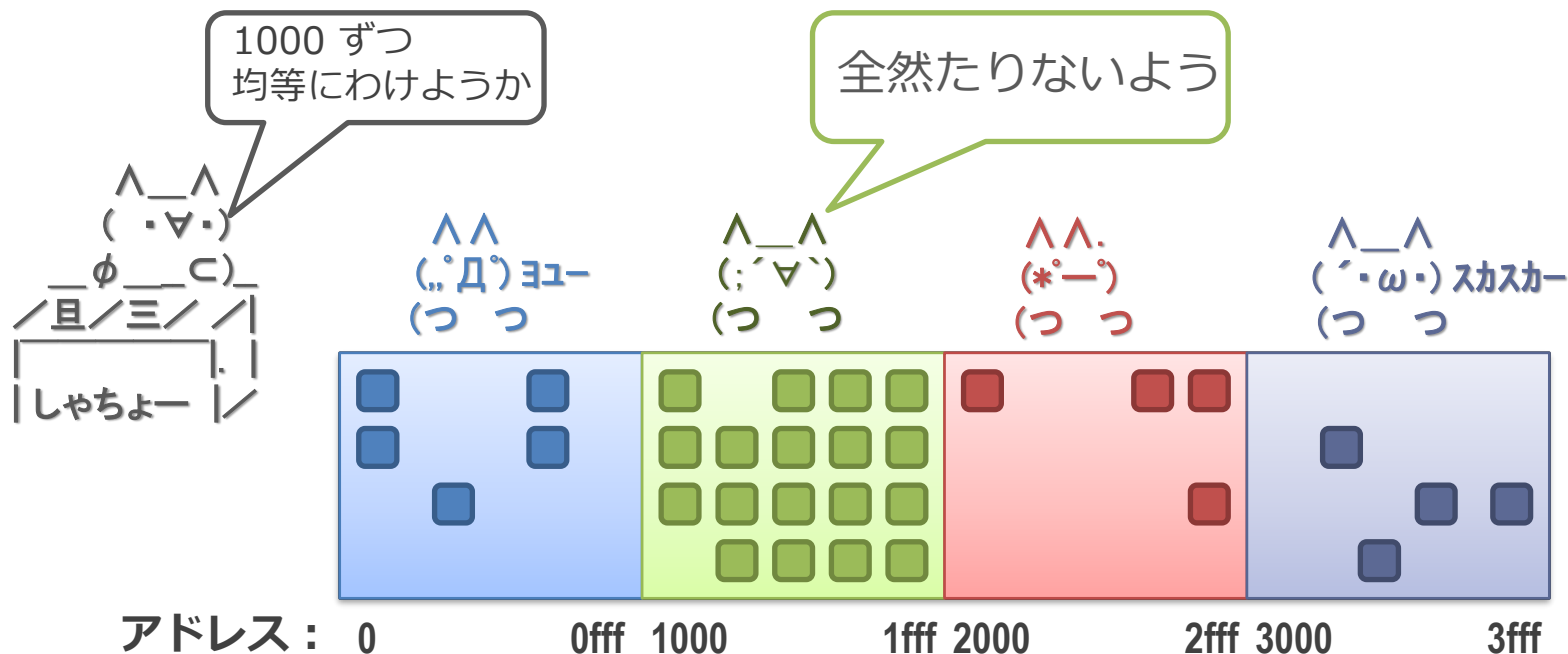
2. 特権モード

仮想メモリのモチベーション




- 前提：複数のプログラムを1つのCPU上で同時に動かすことを考える
 - 上の図では4つのプログラムが動くとする
 - メモリは複数のプログラムで共有される
- 問題：どうやって共有するか？
 1. どうやって領域の割り当てを行う？
 2. どうやって各人の領域を保護する？

1. どうやって領域の割り当てを行う？



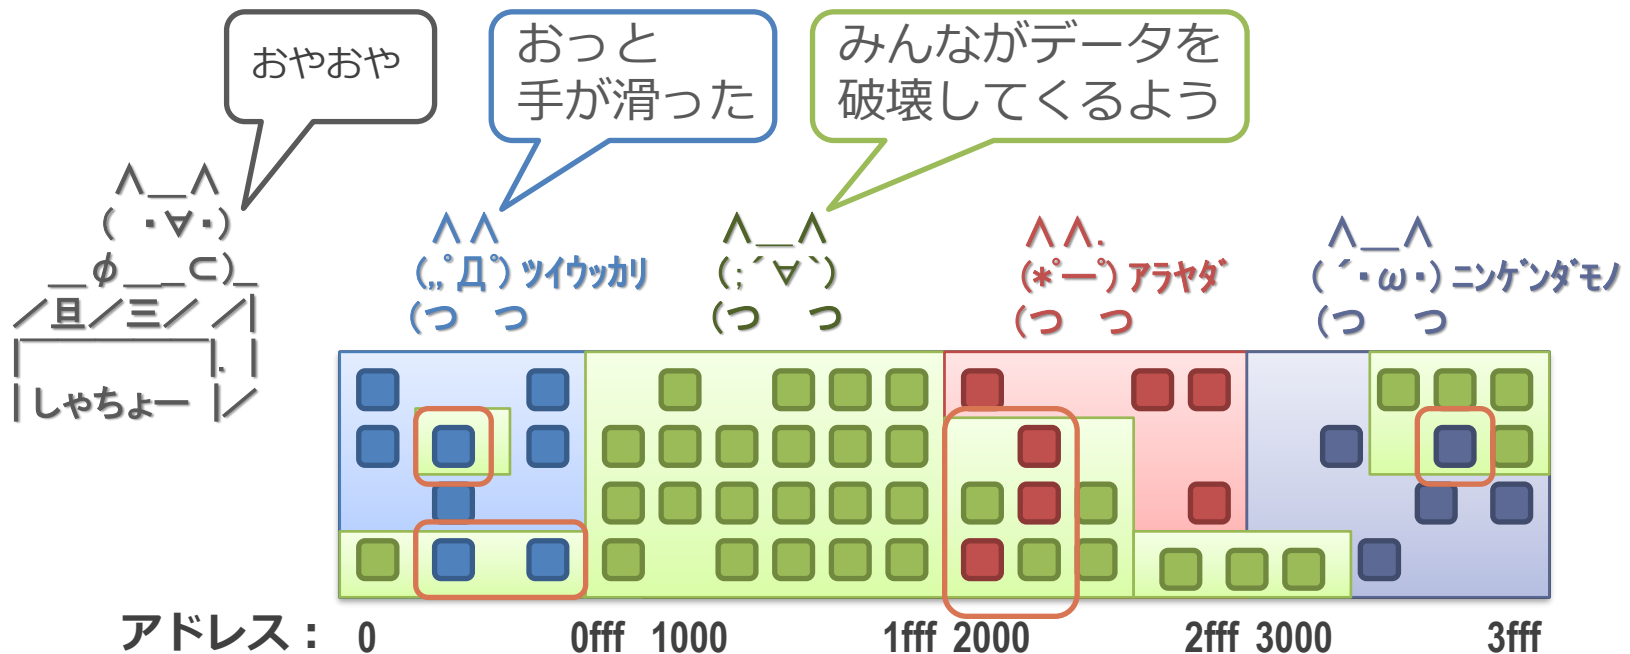
- 単純には均等に分ければ良い
 - しかし、プログラムごとに必要なメモリの量は違うのが普通

1. どうやって領域の割り当てを行う？




- たくさんメモリを使う人に都度割り当てると、メモリ空間が細切れになってとても使いにくい
 - 青の人のメモリ : 0x400-0x7ff, 0xc00-0xffff
 - 緑の人のメモリ : 0x000-0x3ff, 0x800-0xbff, 0x1000-0x2000 ...

2. どうやって各人の領域を保護する？



- 他の人のプログラムの領域をバグで誤って上書きしてしまうことも
 - 例：配列の最大サイズを超えて書き込むと，他のプログラムのメモリが破壊される

2. どうやって各人の領域を保護する？



- 特に OS の管理領域がバグで破壊されると OS ごと落ちかねない
 - 管理領域をユーザーに勝手に見られるのもまずい

仮想メモリ

広くていいねえ

^^
(..D)
(っ っ)



^_^
(^v^)
(っ っ)



^^.
(*ー)
(っ っ)



^_^
(^ω^)
(っ っ)



仮想
メモリ
システム

本当はこれしかないんだけどね

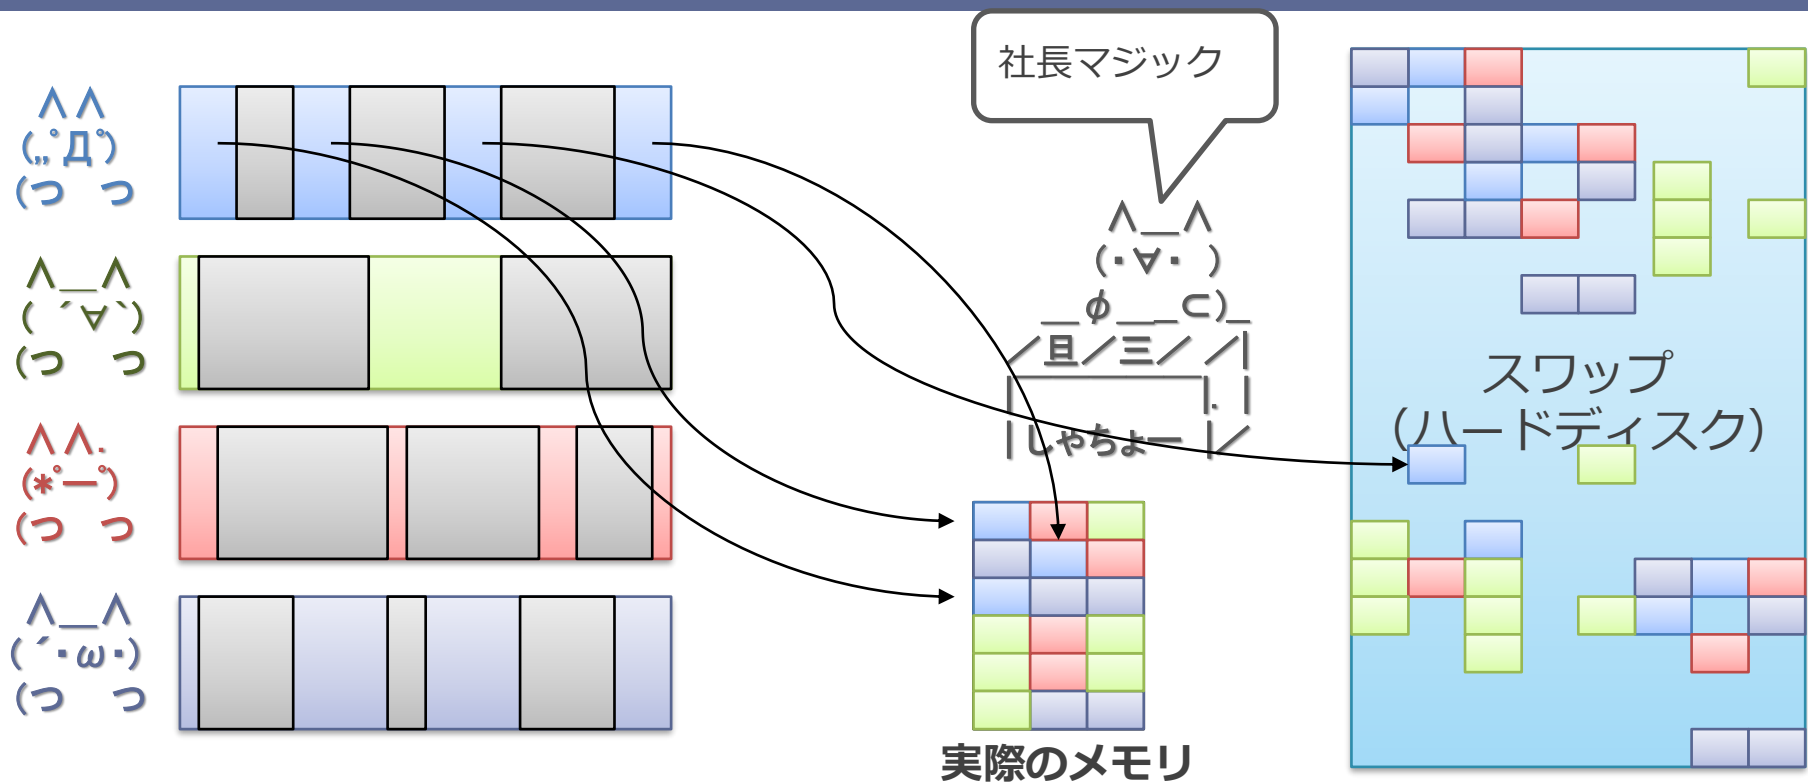
^_^
(.v.)
φ C)
旦 三
| しゃちょー |

実際の
メモリ

■ プログラムごとに専用の大きなメモリが用意されているように「**見せかける**」技術

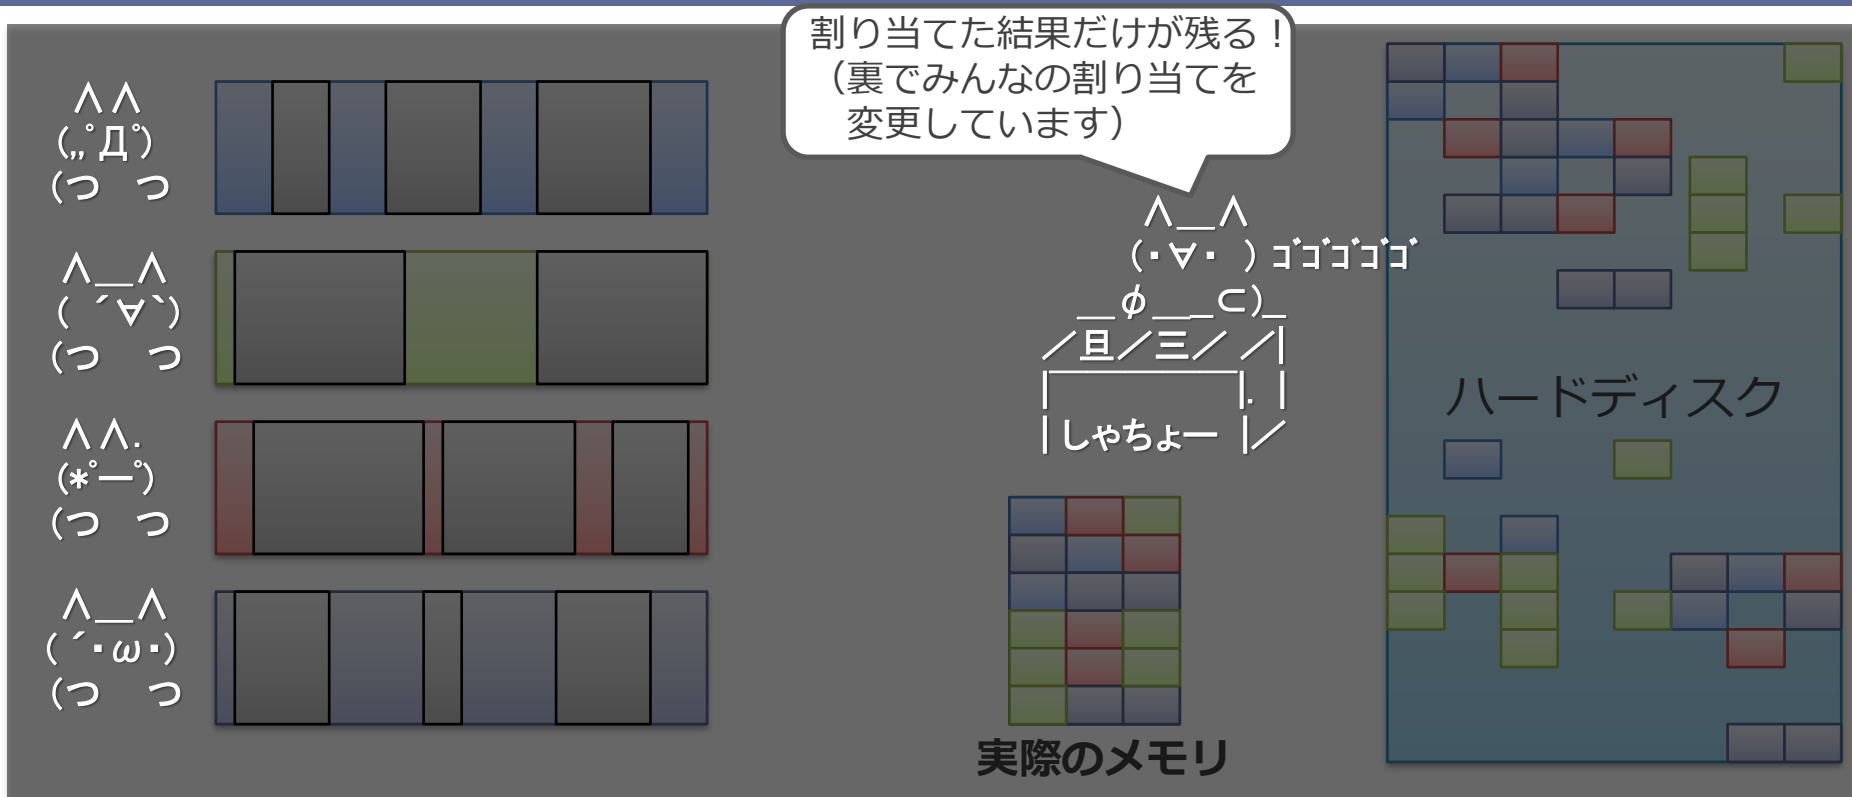
- プログラムからは「自分専用の」メモリがあるかのように見える
- アドレスで指定できる場所はすべて自分の空間
- 他人の空間は読み書きできない

メモリのマップ



- 各人の仮想的なメモリの使っている部分が細切れに実際のメモリにマップされる
 - 足りない場合はより容量が大きな（そして遅い）ハードディスクにマップされる
 - これを「スワップ領域」という
 - ある意味、メモリがスワップのキャッシュになっている
 - これにより、効率的に実際のメモリを共有

マップの更新は透過的に行われる



- これらの管理は OS によって、プログラムからは透過的に行われる
 - 透過的=プログラムの実行を止めて OS が裏で再割当てを行う
 - プログラマはこれらのことを意識しないが良い
 - というか、裏で動いているこれらの管理の動作は通常認識できない


仮想メモリの基本のまとめ

- モチベーション：複数のプログラムでメモリをどうやって共有するか
 1. どうやって領域の割り当てを行う？
 2. どうやって各人の領域を保護する？
- 仮想メモリ：プログラムごとに専用の大きなメモリが用意されているように「見せかける」技術
 - プログラムからは「自分専用の」メモリがあるかのように見える

仮想メモリの詳細

1. 仮想メモリの詳細
 1. 仮想アドレスと物理アドレス
 2. ページ・テーブル
 3. TLB

仮想アドレスと物理アドレス



■ 仮想アドレス（論理アドレスともいう）


- プログラムから見えるアドレス
- C 言語などでポインタに入っているアドレスの数字はこれ

■ 物理アドレス

- 物理的なメイン・メモリのアドレス
- プログラムからは見えない（=どういう数字なのかはわからない）


■ メモリ・アクセス時は，毎回仮想アドレスから物理アドレスにCPU が裏で変換してアクセスする

同じ仮想アドレスが指す物理アドレスは プログラムごとに異なる



- プログラムごとに異なる物理アドレスにマップされる
 - 上の例では, 青の人のアドレス 0x8000 と緑の人のアドレス 0x8000 はそれぞれ異なるアドレスに変換される
- 正確にはプログラムごとではなくプロセスごと
 - 同じプログラムを複数立ち上げた場合, それぞれに専用の仮想アドレスの空間が提供される

逆に違う仮想アドレスから 同じ物理アドレスを共有することもできる



- 同一の物理アドレスを異なるプログラムの仮想アドレスから指す事もできる
 - プログラム間でデータのやり取りをするときなんかを使う
 - OSはこのあたりの機能をフル活用して作られている
 - (来学期の講義で詳しくやるはず)

仮想メモリの詳細

1. 仮想メモリの詳細
 1. 仮想アドレスと物理アドレス
 - 2. ページ・テーブル**
 3. TLB

変換の実装

■ 単純な実装

- 仮想アドレス → 物理アドレス の変換表を用意すれば良い


■ コスト：アドレスが 32 bit だとして, 1 byte 単位で表を作ると...

- データ 1 byte ごとに, その表には 32 bit = 4 byte のアドレスを記録することになる
- 実データの 4 倍の容量が変換表に必要になってしまう

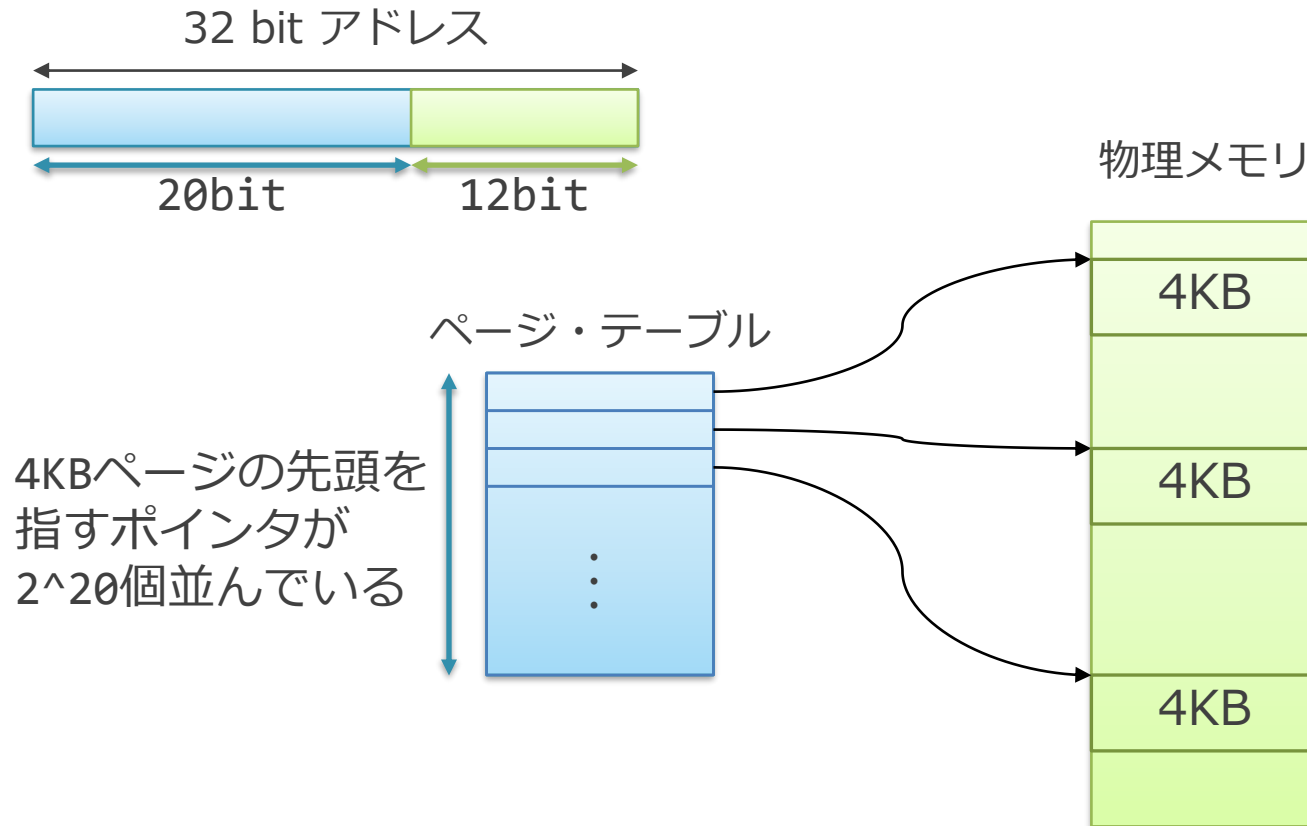
ページ単位での管理

- 変換表に必要な容量を減らすため、通常は「ページ」という単位でまとめて管理される
 - ページ単位の変換表を「ページ・テーブル」と呼ぶ
 - ページのサイズは 4KB から 数 MB ぐらい
 - 命令セットごとに仕様として決まっている
- 例：仮想アドレス上の連続した 4KB の領域（ページ）を、物理アドレス上の 4KB にマップ
 - 1 byte ごとに物理アドレスを覚える必要があったのが、4KB ごとでよくなる（4096 分の 1 の容量で済む）

^^
(。D)
っっ




4KB ページを使った単段ページ・テーブルの例



- まず単段のページ・テーブルを考える
 - アドレス・サイズが 32 bit, ページ・サイズ $2^{12}=4$ KB を仮定


単段ページ・テーブルの動作




■ 仮想アドレス 0x30100f24 のアクセスを考える

- 上位 20 bit である 0x30100 を取り出し、それをインデクスとしてページ・テーブルにアクセス
 - 物理メモリへのポインタはここでは 4B 単位なので、
 - $0x30100 \times 4B = 0xc0400$ にアクセス
- マップされているページの先頭の物理アドレス 0x81234000 を得る
 - 0x81234000 は OS がこの論理アドレスに割り当てたページのアドレス
- 下位 12bit である f24 と結合して 0x81234f24 にアクセス

実際にはページ・テーブルも物理メモリ上に取られる




プロセス切り替えはベース・レジスタの中身を入れ替えで実現する



多段ページ・テーブル


- ページ単位で管理したとしても, なおページ・テーブルは大きい
 - 64 bit のアドレス空間で, ページ・サイズを 4KB とした場合,
 - $(\text{アドレスの個数}) / (\text{ページ・サイズ}) * (\text{アドレスのサイズ}) = (2^{64}) / 4\text{KB} * 64\text{bit} = 16\text{EB} / 4\text{KB} * 8\text{B} = 32\text{PB}$
 - たとえ 1B しかメモリを使わないプログラムでも 32PB が必要に
 - 32 bit のアドレス空間なら大分でしたが, それでも 4MB が必要
- 多段ページ・テーブルと呼ぶ構造で効率良く保持する
 - プログラムで使うメモリ容量に比例した程度の容量でページ・テーブルを作る方法

2 段ページ・テーブルの例



- 複数段のテーブルを経て物理メモリにアクセス
 - LV1テーブル → LV2テーブル → 物理メモリ

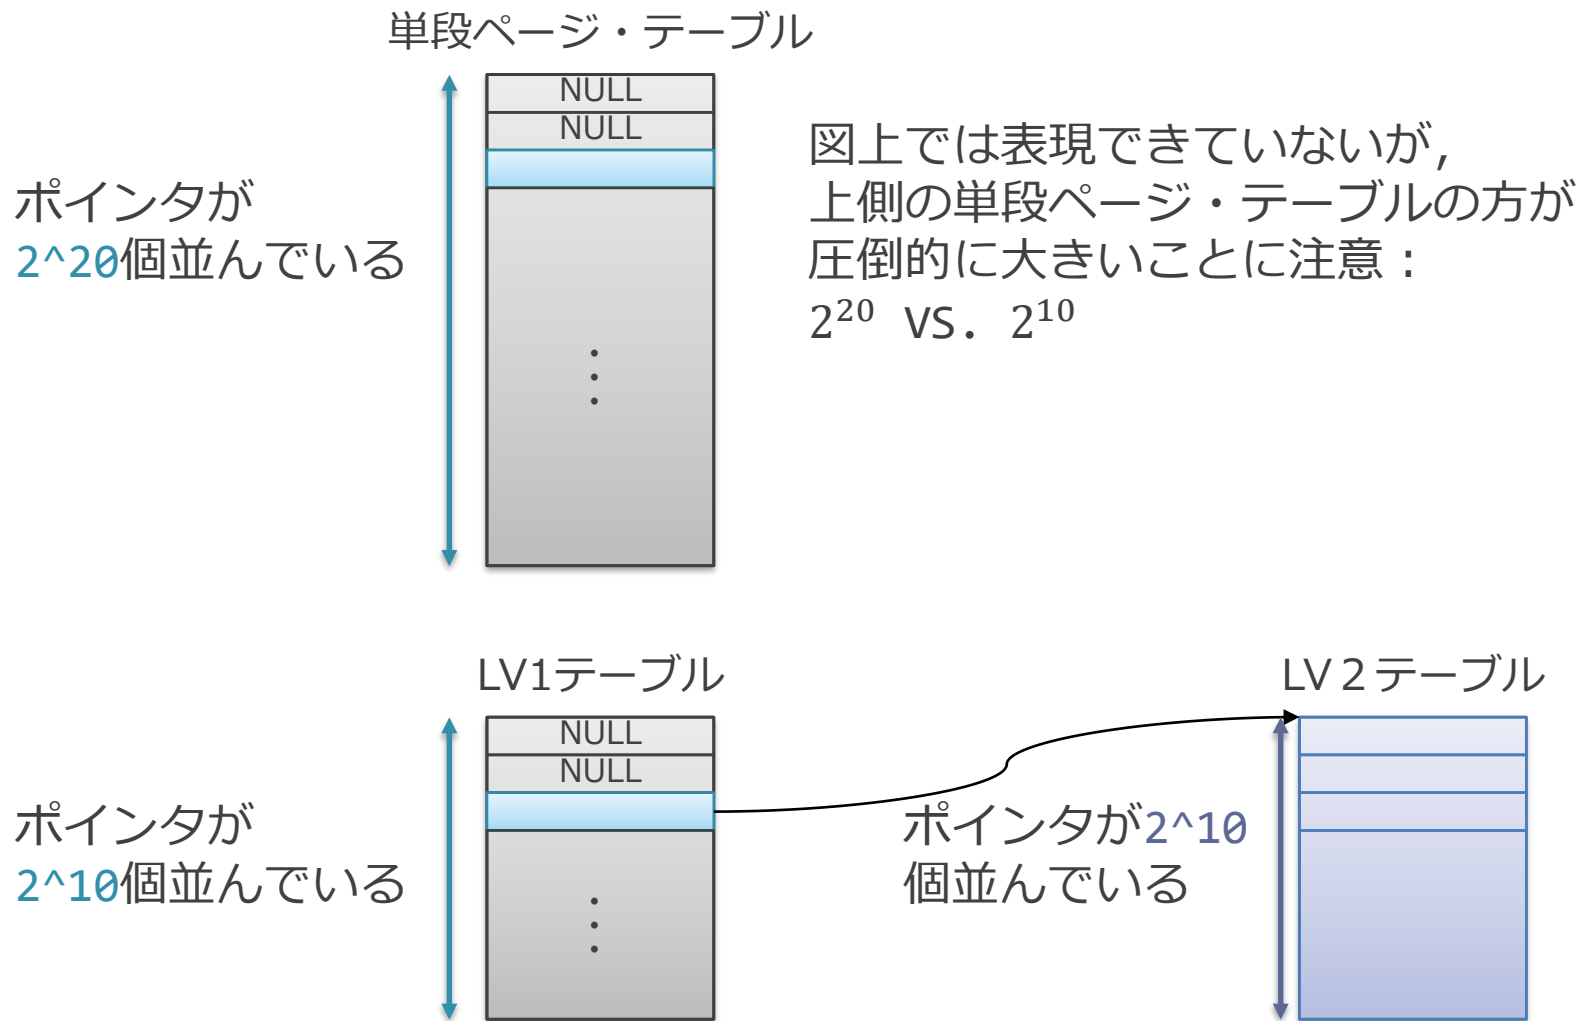
2 段ページ・テーブルのアクセス



■ アクセス方法

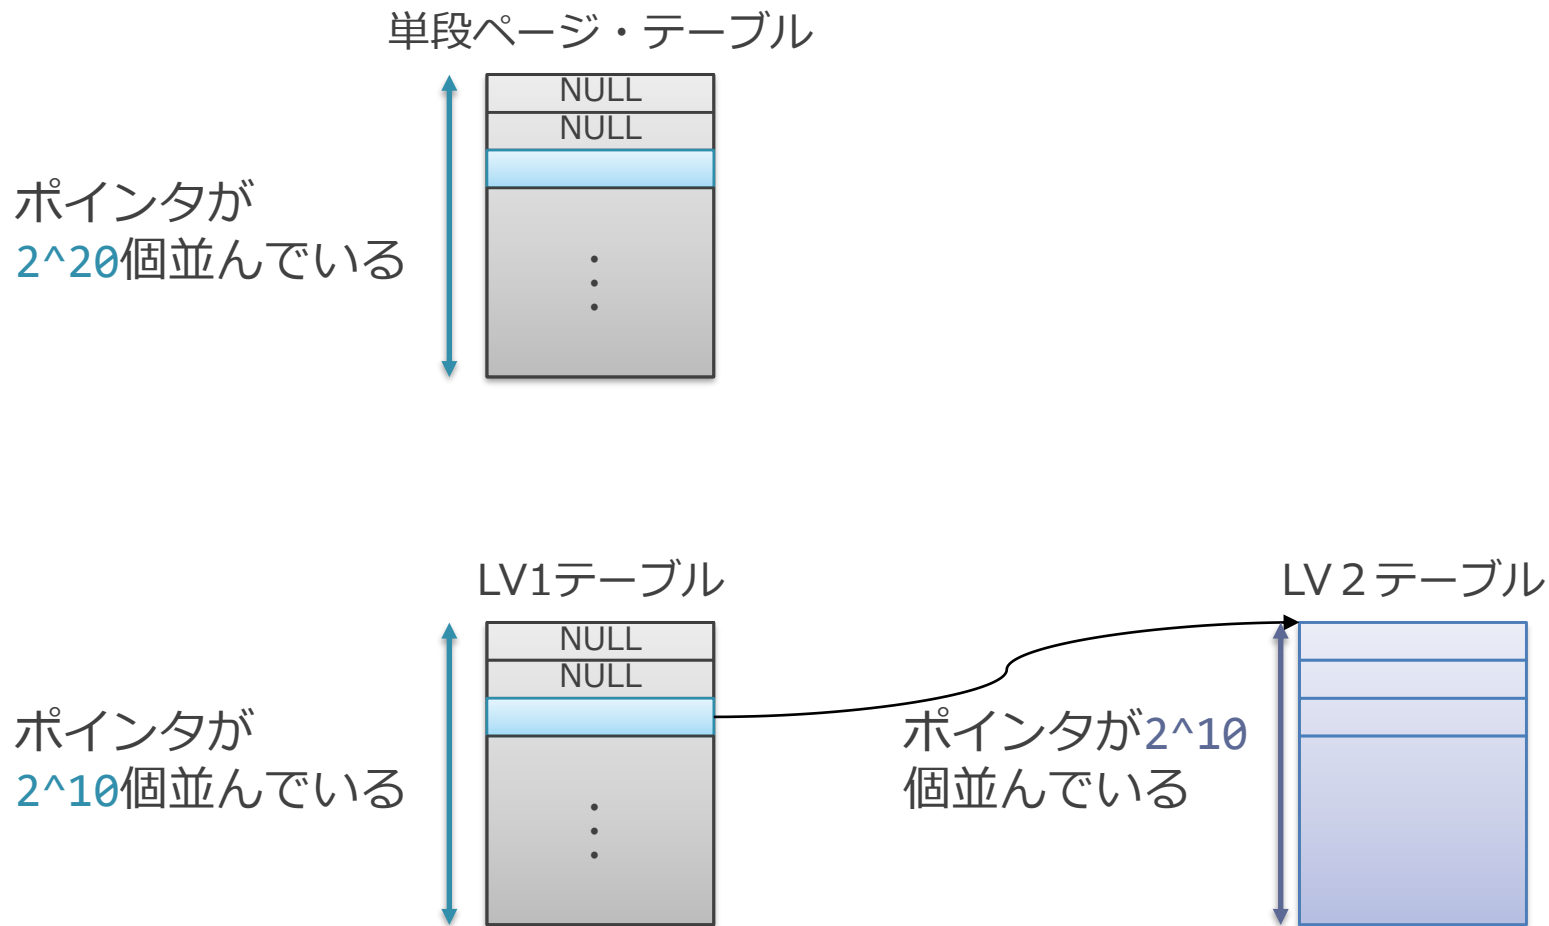
1. 最上位 10 bit をインデクスとして LV1 テーブルにアクセス
2. 次の 10bit をインデクスとして, 1. で得られた LV2 テーブルの先頭アドレスにアクセス
3. 最下位 12 bit をインデクスとして得られた物理メモリ上の 4KB 領域にアクセス

2 段ページの利点：必要な容量が少ない




- 確保された領域に対応するエントリのみ、有効なポインタが入る
 - 未確保の領域は無効なポインタが入る

2 段ページの利点：必要な容量が少ない



- 単段のテーブルと多段の LV1 のテーブルは固定長にせざるを得ない
 - どこに有効なポインタが入っているかわからない
 - LV2 テーブルはその領域が確保された場合のみ存在

2 段ページの利点：必要な容量が少ない



- 4KB のメモリを確保したときにページテーブルに必要な容量：
 - 単段：ポインタが $2^{20}=1024K$ 個
 - 2段：ポインタが $2^{10}+2^{10}=2K$ 個

ページ・テーブルの詳細

- 実際には容量効率を重視してもっと多段になっている
 - x86_64 だと4段
- ページ・テーブルをたぐって仮想アドレスから物理アドレスを得る操作を「ページ・テーブル・ウォーク (Page Table Walk)」と呼ぶ

ページ・テーブルの管理

- ページ・テーブルを使ったアドレス変換は基本的に CPU が行う
 - このため、ページ・サイズなどのテーブルの構造は CPU ごとに仕様で決まっている
 - 昔は変換の一部をソフトで行うものもあったが、今は大概ハードで完結して行う
 - ソフトが介在する場合、オーバーヘッドが非常に大きい
- ページ・テーブルの中身の更新はソフト（OS）で行う
 - 全部ハードでやるとあまりに大変
 - 更新は変換よりも頻度がかなり低い
 - OS ごとにどのようにマップしたいかも異なるし、柔軟性をもたせたい

MMU: Memory Management Unit

■ MMU :

- これまでに説明した仮想メモリの仕組みを実現するハードウェアのこと
- ページ・テーブルのアクセスによる変換などを行う

仮想メモリの詳細

1. 仮想メモリの詳細
 1. 仮想アドレスと物理アドレス
 2. ページ・テーブル
 3. **TLB**

ページ・テーブルの速度面のオーバーヘッド

■ 多段テーブル

- x86_64 の場合, 4 段のページテーブルになっている
 - より容量効率を重視
- これだとメモリ・アクセス毎に追加で 4 回のアクセスが発生
 - 毎回こんなことしたら遅くなりすぎてとても耐えられない

TLB: Translation Lookaside Buffer

- ページ・テーブルのキャッシュ
 - ウォークの結果得られた物理アドレスをキャッシュ
 - 役割は完全にキャッシュだけど、歴史的経緯でバッファと呼ぶ
- 仮想アドレスの上位アドレスでアクセス
 - ヒットすると、対応するページの物理アドレスが一発で得られる
 - ミス時は通常のウォークを行って物理アドレス

TLB: Translation Lookaside Buffer

- 64 エントリぐらい用意されるのが典型的
 - 高速性を優先してエントリ数は非常に少なくなっている
 - ロードやストアの実行の度にアクセスされるから
 - カバーできる範囲が $64 \times 4\text{KB} = 256\text{KB}$ と意外とせまい
- プログラムの実行が切り替わる度にフラッシュされる
 - 仮想アドレスはプログラム間で同じ値が使われる
 - 最近ではプロセス識別子というものが導入されて、フラッシュを避けていることもある
 - 「仮想アドレス+プロセス識別子」でアクセスする

仮想メモリのまとめ

■ 仮想メモリ：

- プログラムごとに専用の大きなメモリが用意されているように「見せかける」技術

■ ページ・テーブル

- 仮想アドレスから物理アドレスへの変換表
- TLB はページ・テーブルのキャッシュ

今日の内容

1. 仮想メモリ
- 2. 特権モード**

モチベーション

■ 仮想メモリ

- プログラムごとに専用の大きなメモリが用意されているように「見せかける」技術

■ ページ・テーブルの操作は誰が行うのか？

- 各プログラムが勝手に好き勝手に操作できてはまずい
- 他のプログラムのメモリへのアクセスが自由にできてしまう

特権モード

■ CPU 内に用意されている特権モード

● ユーザー・モード

- 通常のプログラムが動くモード
- ページ・テーブルの操作は制限されている
- グラフィックやディスクなどの外部デバイスへの操作も制限されている

● カーネル・モード

- OS が動作するモード
- ページ・テーブルの操作などはこのモードの時しか行えない

システム・コール

- 特権が必要な操作を行う場合, OS に要求をなげて実行してもらう
 - カーネル・モードで動く OS に依頼する
 - メモリ確保やファイル読み書き, ページ・テーブルの操作など
- これらの操作は必ず OS を介す
 - 特定のプログラムによりコンピュータ全体の動作を破壊することはできないようにしている
 - たとえば, 「あるプログラムからコンピュータ上の全てのメモリにゼロを書き込む」とかはできない

システム・コール

- 特権が必要な操作を受け付ける関数をシステム・コールと呼ぶ
 - 呼び出しのために、モード遷移を伴う特殊な関数呼び出し命令が用意されている
 - あらかじめ OS で設定された固定のアドレスに強制ジャンプする
 - ユーザー・モードから任意の場所に飛べるわけではない

システム・コール

■ RISC-V の場合 :

- ユーザー・モード から ecall 命令を実行するとカーネル・モードに
- カーネル・モード から eret 命令を実行するとユーザー・モードに

RISC-V 64bit Linux の場合

(具体的なレジスタ番号とかは違うかもしれませんが、間違ったらスミマセン)

■ RISC-V 64bit Linux の場合の例

- ファイルをリネームするシステム・コール `rename()` の呼び出し
- 手順：
 - レジスタ `x17` にシステム・コールの識別番号を設定
 - ◇ RISC-V Linux の `rename` の場合は 1034
 - `x10~x13` に引数を設定
 - `ecall` を実行
- 注：OS ごとにレジスタの使い方等のルールは自由なので、みんな違う

```
// https://github.com/riscv/riscv-linux/blob/riscv-next/include/uapi/asm-generic/unistd.h より
#define __NR_rename 1034
__SYSCALL(__NR_rename, sys_rename)
#define __NR_readlink 1035
__SYSCALL(__NR_readlink, sys_readlink)
...
```


```
li x17 ← 1034 // システム・コール rename の要求番号を設定
ld x10 ← (...) // リネーム対象のファイル名が入っている文字列へのポインタをロード
ld x11 ← (...) // リネーム後のファイル名が入っている文字列へのポインタをロード
ecall          // システム・コール呼び出し. 返り値は x10 に入る
```

システム・コールによるメモリの確保

- Linux では通常はシステム・コール `mmap` によってメモリを確保
 - `malloc` とかを呼ぶと, その奥底では `mmap` が呼ばれている
- `mmap` には確保したいメモリのサイズを渡す
 - `mmap` 内で要求サイズ分だけ仮想アドレスが使えるように, ページ・テーブルを更新
 - プログラムは返ってきた仮想アドレスを使用する
 - ページ・テーブルを直接操作することは通常はない

仮想メモリによる保護

- ユーザー・モードからは、他のプログラムが持つメモリは読めない
 - アドレス変換は自動で強制的に行われる
 - このため自分に用意されたページ・テーブルから指されていないものは参照しようがない
 - カーネル・モードはページ・テーブル自体を自由に切り替えられるので任意のメモリにアクセスできる

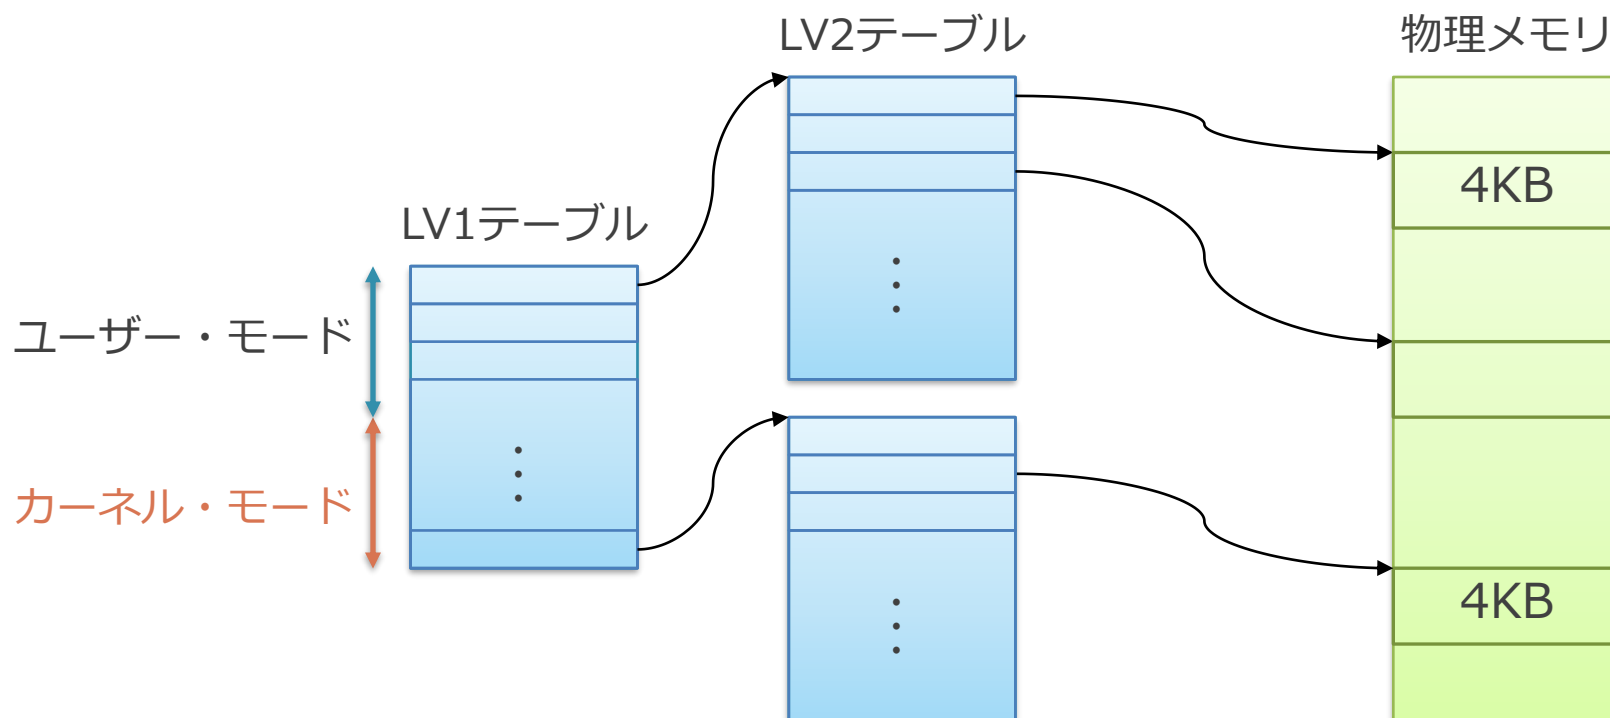


ページごとの保護

- ページごとにさらに、モードごとの権限を設定できる
 - ページ・テーブル内にポインタと一緒に格納
- 「カーネル・モードでは読めるがユーザー・モードでは読めない」のような属性が設定できる
 - これらのチェックに違反すると OS にプログラムの実行を止められる
 - 「Access Violation」や「Segmentation Fault」でプログラムが停止するのは、この機能による

ページごとの保護を利用した 仮想アドレスの共有による最適化


- ユーザー・モードと OS は仮想アドレスを共有することが多い
 - たとえば, 全てのプログラムの仮想アドレス空間の後ろ半分は OS が使用など
 - 利点: システム・コール呼び出し時にページ・テーブルを OS 用仮想アドレスに切り替えなくてよくなる



ページごとの保護を利用した 仮想アドレスの共有による最適化

■ ページごとの権限を利用して保護

- ユーザー・モードからでも OS の物理メモリにページ・テーブルを介して到達可能
- カーネル領域はユーザーから読むと落ちるよう設定するので安全
- エントリに「カーネルのみ許可」と権限が設定される



仮想メモリと特権モードによる保護のまとめ

- CPU には操作できる権限が設定されたモードがある
 - ユーザー・モード
 - カーネル・モード
- ユーザー・モードではメモリなどを変更する操作は自由には行えない
 - カーネル・モードで動作する OS に依頼して行う
 - 当然他人のファイルやメモリへアクセスしようとするれば落とされる
- 他のプログラムや OS 領域のメモリを読むことは基本的にできない
 - プログラムごとに独立した仮想アドレス空間を提供
 - ページごとのアクセス権限の設定

まとめ

1. 仮想メモリ

1. モチベーションと基本
2. 詳細
 1. 仮想アドレスと物理アドレス
 2. ページ・テーブル
 3. TLB

2. 特権モード

1. システム・コール
2. メモリ保護

課題 1 1

- 以下のような状況の仮想メモリについて考える：
 - 仮想アドレス空間と物理アドレス空間は共に 32bit である
 - 単段ページ・テーブルを使用
 - ページ・サイズは 64KB である
 - ベース・レジスタには物理アドレス 0x20000000 が設定されている
 - 仮想アドレス 0x10000000 と 0x0fea0000 から始まるページには、それぞれ物理アドレス 0x30000000 と 0x30010000 から始まるページが割り当てられているものとする
 - TLB は存在しない

課題 1 1

- (1) 仮想アドレス 0x10002000 に格納されている値を読み出す際にアクセスされる物理アドレスをすべてあげよ
- (2) 仮想アドレス 0xfea51fff に格納されている値を読み出す際にアクセスされる物理アドレスをすべてあげよ
- (3) 仮想アドレス 0x10000000 と 0xfea50000 から始まる 2 つのページが確保されている場合を想定する。この時に使用される物理メモリの容量の合計（ページ・テーブルとページそのもの）を求めよ
- (4) (3)と同様の条件で、2 段ページ・テーブルを使用した場合に使用される物理メモリの容量の合計を求めよ。この時 LV1 と LV2 に使用されるアドレスのビット幅は等しいものとする。
- 2023/07/24 16:43 すいません、アドレスが一部間違っていたので講義後に更新しました

提出方法

■ 以下を提出：

1. 課題 1 1：

- 提出は Moodle の「課題 1 1」のところからお願いします
- 紙に書いた場合は写真を撮ってアップロードしてください

2. 感想や質問：

- 「感想や質問」のところに投稿してください
- わからない場所がある場合、具体的に書いてもらえると良いです

■ 提出締め切り

- Moodle に設定した締め切りまで（7/30 日曜日の 23:59 頃、要確認）

■ 注意：

- 課題の出来は、ある程度努力したあとがあれば良しです
 - 必ずしも正解していなくても良いです

来週 7/31 について

- 7/31 は休講の予定だったが、実施できるかもしれない
 - 実施できた場合、課題の解説と質問に答える回に
 - 必ずしも出席しないで良いです
 - この日は新しく課題はも出さないです

期末試験について

- 8/7 予定
- A4 裏表 1 枚 手書きのみの持ち込み可
- 基本的に課題で出した部分を中心に出题する予定

練習問題について

- すいません、用意したいと思っておりますが、まだ時間がとれてないです
- 基本的には課題で出した問題の、パラメータが違うものを用意したいと思います
- もしもですが、問題作って投げてくれる人がいれば、解答の確認をこちらでやって公開したいです

質問とか感想

- 行列積の、最内周ループのアクセス範囲が横向きになっているが重要という部分が理解できなかったので説明していただきたいです。
 - 連続したアドレスのデータは同じライン上にのるため

- 行列積の動作例のところで2次元目を連続にするという意味がよくわかりませんでした。1次元とどのように異なるのでしょうか。

- 連想度が高い方が、ヒット率があがると思っていたのに、そんなこと無かったので、多分間違えています。。。課題のやり方の例を載せてもらえると嬉しいです。
- 基本的にはそうだが、実はそうとも限らないことがある

質問とか感想

- セットアソシアティブでラインに値を読み込む時、仮にラインが16バイトでアクセスされたアドレスが0x800だった場合、0x800から連続して16バイト分のデータ(つまり、数字4文字分)を読み込むのか、0x800の次にアクセスされるアドレスが0x800に連続してなくても、その次にそのデータが入るのか分かりません。
- (質問の意味がわかりにくくてすみません。直接質問します！)

- 4エントリと4セットは同じものですか？

- 課題10についての質問ですが、ラインサイズが8Bということは、ダイレクトマップで0x8000を読んだ時点で、0x8007までキャッシュにのっていると思ったのですが、それだと問題自体がよく分かりません。連続したメモリではないのでしょうか？

- 課題がさっぱりわかりませんでした。前の授業で説明していたら申し訳ないのですがアクセス系列とは何でしょうか。

- 4エントリだと少なく感じたのですが、実際は何エントリぐらいあるのでしょうか？
- LV1 で 512, LV3 までいくと数万ぐらいまで

質問とか感想

- 例えば、ラインが16バイトだった場合、buf[0]のアクセス時にbuf[1]からbuf[15]まで読むとのことですが、buf[17]のアクセス時はbuf[18]からbuf[32]まで読むという解釈で間違っていないですか？また、このときbuf[0]からbuf[15]はエントリの消費はしないという解釈も合っていますか？アドレスの幅は今回の課題では利用しませんか？

- コンフリクトがおきてキャッシュがほとんど利用できない、というところが理解できませんでした。大きな二次元配列でアドレスが等間隔になることによってコンフリクトが起きてしまうのでしょうか？コンフリクト自体よく理解できていません。今回の授業で、何回か前の内容のfor文の順番によって、かかる時間が変わるというのが理解できました。

質問とか感想

- 行列積の計算の実行時間について、授業で紹介されていたような結果になるのはC言語で実行したからであって、Pythonなど他の言語だと変わらないといったような話を聞いたことがあるような気がします。これがなぜなのかあまり理解できていないので、授業の内容からは外れてしまいますが教えていただきたいです。
- キャッシュによる速度差については, Python でも同じような影響があるはず

質問とか感想

- アドレス下位がかぶると(競合とよぶ)、上書きされる。8000, 7000, 0100の順にアクセスがあると、0番しか使えない という今回の資料20ページのところがあまりよくわからなかったです。課題のアクセス3種類のうち、2と3でこの考え方を使うと思って、たとえばダイレクトマップで2つ目のアクセスについて考えるとき、0x8000と0x9000と0xA000と0xB000にアクセスするとき、この4つすべてのアドレス下位が0でセット位置がかぶっているので、いちばん最後にアクセスした0xB000が上書きされて残り、結果的に位置0にタグ0x580、ライン0が残ると思いました。この解釈は間違っていますか？(タグの0x580は0xB000を2進数に直して、ラインの位置下3桁とセット位置をラインの位置に続いた2桁ぶんを除いたそれ以上の桁を16進数に戻した値です。)

- 空間的局所性がいまいちよくわかっていないので、具体例がもう少しあるとありがたいです。

- スライド16の上記の例の8000にあった33を保持の8000はキャッシュの8001のことでしょうか？

- CPUがアドレスを読み込む時はまずキャッシュにアクセスしてアドレスがあるかをメモリを確認するより先に確認するという認識であってますか。

- スライド29のラインはキャッシュ内のデータの格納方法の話ではなく、CPU全体でのデータの扱い方の話なのではないでしょうか。ラインごとまとめてメモリからキャッシュに置くという作業はもしキャッシュがまだ何もなかったときにとても時間がかかりそうだなと思いました。

質問とか感想

- 課題の(3)の意図があまり分からなかったです。各アクセスのアドレスの並びによって起こるヒット率の偏りの要因を聞いているのでしょうか？
- 空間的局所性と時間的局所性がよく分からず、課題の時に悩みました。

- 質問なのですが、アクセスのヒット時は空間的局所性または時間的局所性のどちらか一方が必ず関係している(ヒットの理由がそのどちらかに必ず分類される)という認識で合っていますか？

- タグからラインに行ってデータをとる時、どのようにして複数あるデータから特定のデータを取り出すかがよく分かりませんでした。

- フルアソシエイティブの「まず全てのタグを読み出す」の段階があまり理解できませんでした。キャッシュ容量を超えるデータを読み込んだ場合には最初からキャッシュに入る分だけが格納され、その後更新はされないということでしょうか？

- ライン単位のやり取りでラインが16byteだった時buf[0]のアクセス時にbuf[1]~buf[15]まで読むと言うことは理解できたのですが、bufはどのような順番で番号がつけられるのかわかりませんでした。また、例えば連想度が2だった時は、横並びの2つでそれぞれbuf[a]buf[b]と数えるのか、二つまとめてbuf[a]と数えるのかについても教えていただきたいです。

- 前々回の課題を間違えて質問と感想欄に投稿してしまっていたのですが、救済はありますか？
- （この人に限らずですが）そういうのがありましたら、忘れそうなのでメールで連絡しておいてください

質問とか感想

- テストについてなのですが、例えば「課題のような問題で8割」「その他2割」のような目安を出していただけるとありがたいです。
- まだ作ってないので、ちょっとなんとも言いがたいです
- 基本的には課題のような問題が多めで出すつもりです
- あと基本として、2進と16進、10進の数字の相互変換は出来るようになっておいてほしい

- 茗荷谷駅の近くに和菓子の食べログ百名店、一幸庵があります。お菓子屋さん探しているようだったのでお勧めです。